


THEME : Détection de la malaria
sur les images cellulaires à travers
deux modèles de DL et déploiement
du modèle optimal



Réalisé par :

Fatou Kine Dieng SARR

Prince Simba ALIMASI



PLAN

- Introduction CNN/ResNet
- principe de fonctionnement
- Application en médecine (
 - Malaria (Paludisme))
- Présentation des images (data)
- Présentations de votre pipeline
- Présentation des résultats
- Interpretation
- Conclusion et perspectives

INTRODUCTION AUX RESEAUX DEEP LEARNING



INTRODUCTION AUX RESEAUX DEEP LEARNING



CNN

Les réseaux de neurones convolutifs (CNN), également connus sous le nom de ConvNets, sont une classe de réseaux de neurones profonds spécifiquement conçus pour traiter des données structurées en grille, telles que des images. Leur architecture, caractérisée par des couches de convolution et de pooling, permet une hiérarchie de représentations apprises, rendant les CNN particulièrement efficaces dans des tâches de vision par ordinateur telles que la classification d'images.

RESNET


"Residual Network" (RESNET) est une architecture de réseau neuronal profond introduite pour résoudre le problème de la rétropropagation difficile dans les réseaux très profonds. Son innovation clé réside dans l'utilisation de connexions résiduelles, permettant le passage direct de l'information à travers les couches du réseau, facilitant ainsi l'entraînement de modèles profonds.



PRINCIPE DE FONCTIONNEMENT



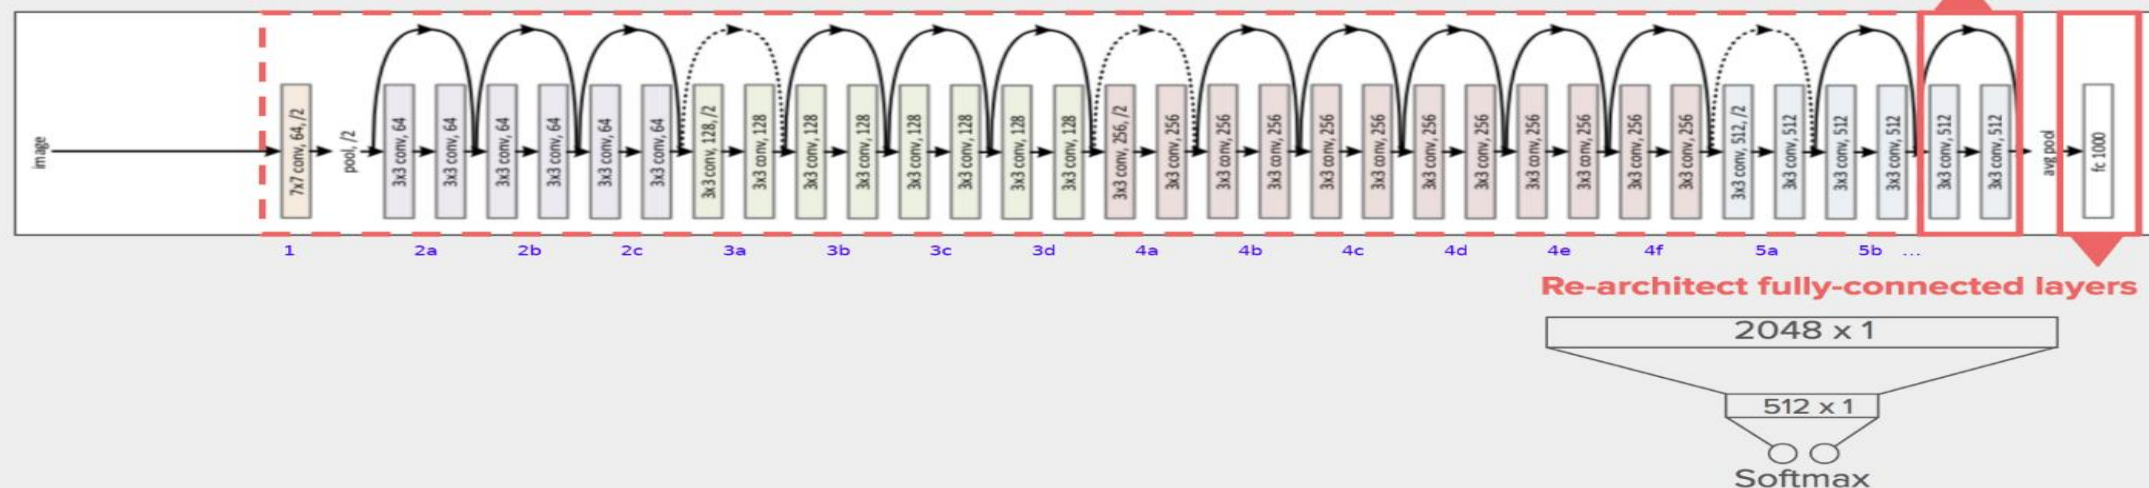
Principaux composants et étapes du fonctionnement d'un CNN



Architecture d'un réseau résiduel ResNet

Retrain ResNet50

ResNet50 Diagram



APPLICATION EN MEDECINE



APPLICATION EN MEDECINE

The background features several abstract geometric shapes in shades of teal and purple. In the top right, there is a sphere and a hexagon. In the bottom right, a large, thick, curved shape resembling a 'C' or a partial ring is visible. In the bottom left, there is a smaller, curved shape. In the center, there is a cone-like shape.

L'utilisation des models de Deep Learning en médecine s'étend à divers domaines, de la détection précoce des maladies à l'analyse d'images médicales complexes.

Ces technologies contribuent à améliorer la précision des diagnostics

à accélérer les procédures médicales et à fournir des solutions innovantes pour les professionnels de la santé

MALARIA



MALARIA

La malaria est une maladie infectieuse transmise par les moustiques et causée par des parasites du genre Plasmodium. Elle est prévalente dans les régions tropicales, affectant des millions de personnes chaque année.

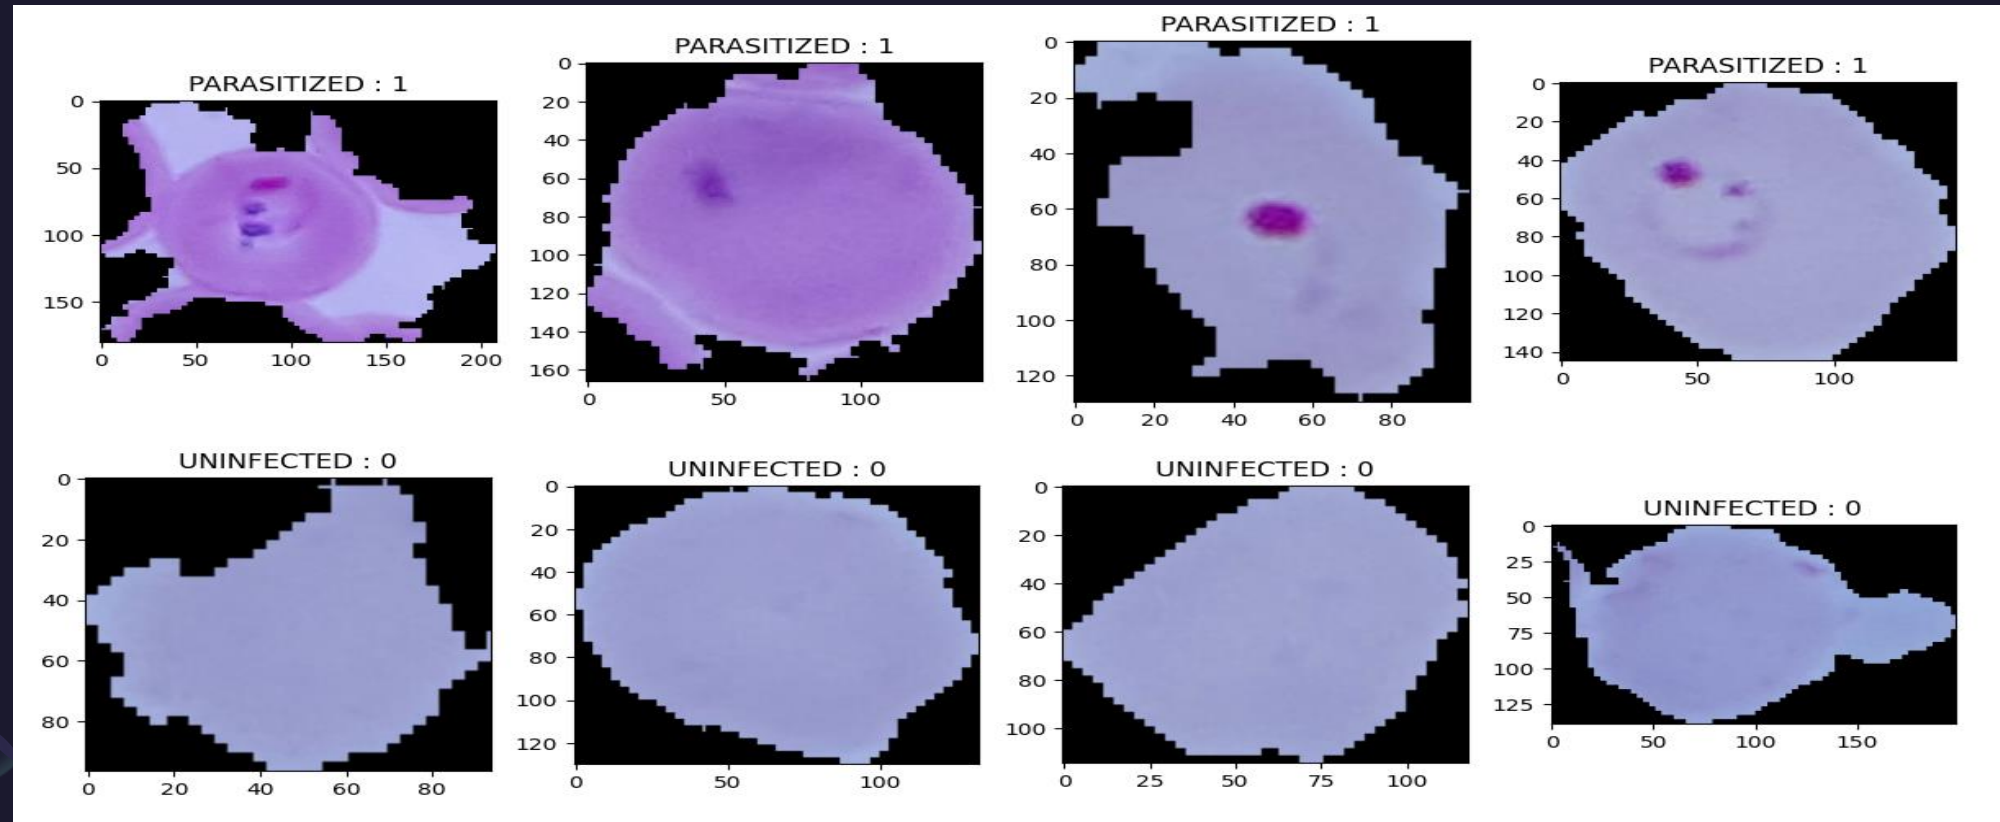
En médecine, le Deep Learning, et en particulier les Convolutional Neural Networks (CNN) ou encore les réseaux des neurones résiduels, sont utilisés pour la détection automatique de la malaria à partir d'images microscopiques de gouttes de sang. Ils peuvent apprendre à reconnaître les parasites du Plasmodium avec une grande précision, contribuant ainsi à automatiser le processus de diagnostic.

Cette application de Deep Learning accélère le dépistage, permettant une intervention plus rapide et améliorant l'efficacité des efforts de lutte contre la maladie.

PRESENTATION DES IMAGES



Illustration des caractéristiques des cellules infectées ou non par la malaria




PRESENTATION DU PIPELINE



Présentation du Pipeline

Figure 6: cycle de vie du processus



PRESENTATION DES RESULTATS



Hyperparamètres

il a été fixé les mêmes hyperparamètres ainsi que leurs valeurs afin de les évaluer sur les mêmes bases. Il s'agit :

- Epochs: 10
- batch_size=100
- Callbacks
- Loss = binary_crossentropy
- Taille data (ci-dessus)
- Repartition de données : 70/30 %

Métrics

Nous considérons comme metrics de comparaison : Le score de précision, les courbes d'apprentissage (de perte et de précision), la matrice de confusion puis les Epochs.

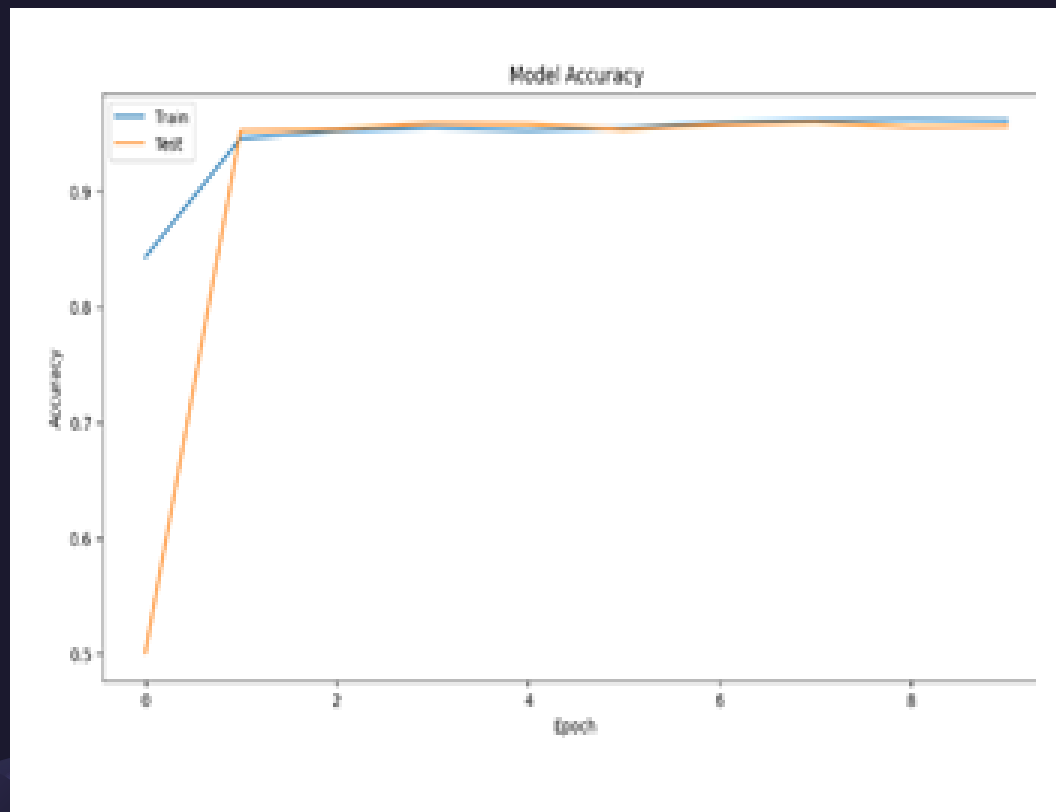
Metrics

Précision

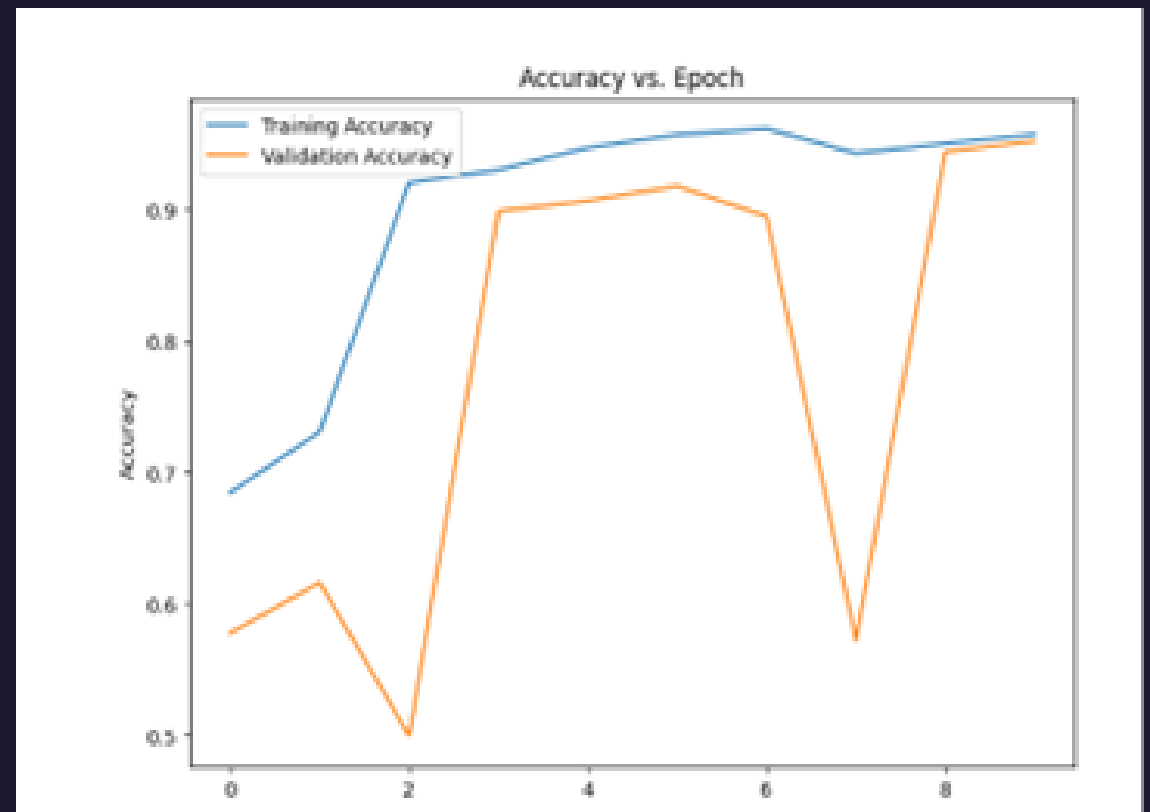
	CNN	ResNet
Score de précision (test)	0.95	0.9396

Courbes d'apprentissage

CNN




ResNet

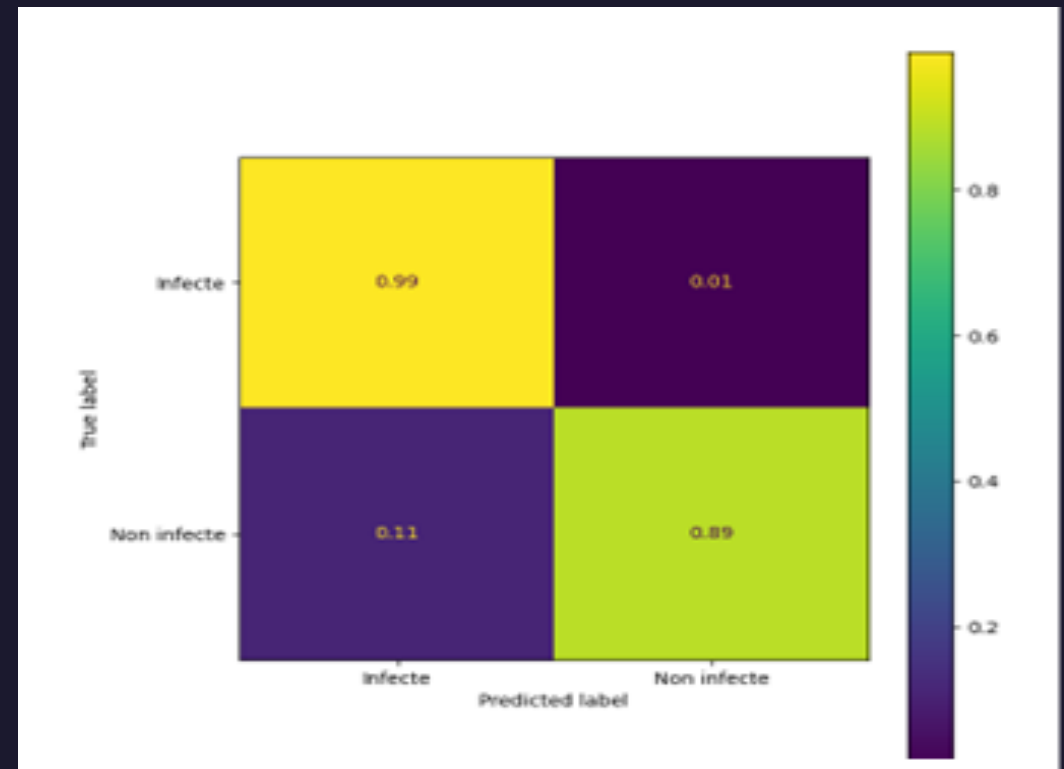


Matrices de confusion

CNN



ResNet



Epochs

CNN

```
Epoch 1/10
303/303 [=====] - 992s 3s/step - loss: 0.4439 - accuracy: 0.8434 - val_loss: 2.4859 - val_accuracy: 0.5006
Epoch 2/10
303/303 [=====] - 945s 3s/step - loss: 0.1706 - accuracy: 0.9460 - val_loss: 0.1550 - val_accuracy: 0.9527
Epoch 3/10
303/303 [=====] - 939s 3s/step - loss: 0.1522 - accuracy: 0.9523 - val_loss: 0.1582 - val_accuracy: 0.9539
Epoch 4/10
303/303 [=====] - 945s 3s/step - loss: 0.1432 - accuracy: 0.9552 - val_loss: 0.1414 - val_accuracy: 0.9592
Epoch 5/10
303/303 [=====] - 948s 3s/step - loss: 0.1433 - accuracy: 0.9529 - val_loss: 0.1314 - val_accuracy: 0.9582
Epoch 6/10
303/303 [=====] - 941s 3s/step - loss: 0.1421 - accuracy: 0.9549 - val_loss: 0.1796 - val_accuracy: 0.9537
Epoch 7/10
303/303 [=====] - 945s 3s/step - loss: 0.1206 - accuracy: 0.9598 - val_loss: 0.1129 - val_accuracy: 0.9582
Epoch 8/10
303/303 [=====] - 944s 3s/step - loss: 0.1170 - accuracy: 0.9616 - val_loss: 0.1173 - val_accuracy: 0.9599
Epoch 9/10
303/303 [=====] - 937s 3s/step - loss: 0.1117 - accuracy: 0.9623 - val_loss: 0.1554 - val_accuracy: 0.9558
Epoch 10/10
303/303 [=====] - ETA: 0s - loss: 0.1197 - accuracy: 0.9614Restoring model weights from the end of the best epoch: 7.
303/303 [=====] - 932s 3s/step - loss: 0.1197 - accuracy: 0.9614 - val_loss: 0.1231 - val_accuracy: 0.9566
Epoch 10: early stopping
```

ResNet

```
Epoch 1/10
194/194 [=====] - 2794s 14s/step - loss: 0.7784 - accuracy: 0.6845 - val_loss: 4.7659 - val_accuracy: 0.5776
Epoch 2/10
194/194 [=====] - 2763s 14s/step - loss: 0.5798 - accuracy: 0.7306 - val_loss: 1.0435 - val_accuracy: 0.6160
Epoch 3/10
194/194 [=====] - 2856s 15s/step - loss: 0.2070 - accuracy: 0.9200 - val_loss: 26.7883 - val_accuracy: 0.4996
Epoch 4/10
194/194 [=====] - 2874s 15s/step - loss: 0.1773 - accuracy: 0.9298 - val_loss: 0.2895 - val_accuracy: 0.8984
Epoch 5/10
194/194 [=====] - 2845s 15s/step - loss: 0.1434 - accuracy: 0.9467 - val_loss: 0.2493 - val_accuracy: 0.9063
Epoch 6/10
194/194 [=====] - 2880s 15s/step - loss: 0.1172 - accuracy: 0.9567 - val_loss: 0.2081 - val_accuracy: 0.9175
Epoch 7/10
194/194 [=====] - 2875s 15s/step - loss: 0.1059 - accuracy: 0.9614 - val_loss: 0.4867 - val_accuracy: 0.8945
Epoch 8/10
194/194 [=====] - 2870s 15s/step - loss: 0.1587 - accuracy: 0.9424 - val_loss: 1.3795 - val_accuracy: 0.5718
Epoch 9/10
194/194 [=====] - 2874s 15s/step - loss: 0.1462 - accuracy: 0.9499 - val_loss: 0.1830 - val_accuracy: 0.9438
Epoch 10/10
194/194 [=====] - 2887s 15s/step - loss: 0.1230 - accuracy: 0.9569 - val_loss: 0.1363 - val_accuracy: 0.9517
```


INTERPRETATION



Interprétation

The slide features several decorative geometric shapes in a teal-to-blue gradient. In the top right, there is a sphere and a cube. On the right side, a large, thick, curved shape resembling a 'C' or a partial ring is visible. In the bottom left, there is a small, thick, curved shape. In the bottom center, there is a cone-like shape.

Nous nous sommes efforcé d'employer les mêmes hyperparamètres dans les 2 modèles afin de fournir une conclusion objective.

De façon nuancée, les résultats obtenus permettent de déterminer que le CNN a présenté les meilleurs résultats de façon globale avec l'utilisation des mêmes hyperparamètres.

CONCLUSION ET PERSPECTIVES



Courbes d'apprentissage



Conclusion

Les modèles de ML facilite et accélère le diagnostic des différentes analyses basées sur les images radiologiques. Elles se constituent en un atout pour le personnel de soins de santé.

Perspectives

- Employer les techniques d'optimisation de nos hyperparamètres afin d'utiliser les meilleurs des hyperparamètres de ceux-ci dans le but d'obtenir les meilleurs résultats de nos modèles
- Ou encore l'utilisation des modèles préentraînés avec les hyperparamètres optimaux.



Thank you

